

REGRESSÃO PARA PESQUISAS SOCIAIS

Aula 2 - Modelagem de dados de natureza contínua

Thiago Cordeiro Almeida

Doutorando, Centre d'Estudis Demogràfics (CED, Espanha)

Pesquisador Assistente, Cebrap

September 17, 2026



ANTES DE COMEÇAR...

lista de presença!



ANTES DE COMEÇAR (2)...

- Dúvidas gerais sobre a aula anterior?
- Exercício da aula anterior: dúvidas, comentários, considerações?



ESTRUTURA DA AULA

Tópicos que vamos cobrir hoje são:

- Fluxo de análise de dados contínuos com o uso de modelagem
- Conceitos, noções (e jargões) econométricos
- Exemplo empírico do dia
- Regressão linear simples
 - Intuição e formalização
 - Propriedade e pressupostos
 - Mão na massa!
- Regressão linear multivariada
 - Intuição e formalização
 - Novidades em relação à regressão linear simples
 - Mão na massa!: interpretação




FLUXO DE ANÁLISE DE DADOS CONTÍNUOS

A partir do uso de modelos



FLUXO DE ANÁLISE DE DADOS

Fluxo 'pseudo'-hipotético-dedutivo de modelagem de dados



CONCEITOS E DEFINIÇÕES ESTATÍSTICAS IMPORTANTES

Modelos probabilísticos



MODELOS PROBABILÍSTICOS

- Na aula anterior, exploramos diferentes formas de analisar descritivamente a distribuição de determinado fenômeno através de diferentes tipos de medida.
- Em termos estatísticos, para cada distribuição observada em uma amostra, há (*ou haveria*) um modelo teórico que descreveria estatisticamente essa mesma distribuição.



Exemplo: programa pé-de-meia.

Qual a parcela dos estudantes que tiveram nota em matemática acima da média do ENEM dentro do universo de pessoas que participaram do programa?

ABORDAGEM EMPÍRICA

ABORDAGEM PROBABILÍSTICA



Exemplo: programa pé-de-meia.

Qual a parcela dos estudantes que tiveram nota em matemática acima da média do ENEM dentro do universo de pessoas que participaram do programa?

ABORDAGEM EMPÍRICA

Calcularia a proporção de pessoas que tiveram a média acima como:

$$p(X) = \frac{e}{n}$$

Em que,

- e : evento – num. estudantes com nota acima da média;
- n : observações – num. estudantes que fizeram o ENEM e participaram do programa.

ABORDAGEM PROBABILÍSTICA

1. Estabeleceria o evento de interesse e o universo amostral de análise
 - **Evento:** parcela de estudantes que participaram do ENEM e do programa os quais tiveram nota acima da média em matemática.
 - **Universo amostral:** estudantes que participaram do ENEM e do programa.
2. Estabeleceria o modelo probabilístico que se associa ao evento de interesse
3. Estimaria a probabilidade desse evento de interesse ocorrer.



ABORDAGEM EMPÍRICA = ABORDAGEM PROBABILÍSTICA

Sob o pressuposto de que nossa amostra de estudantes que participaram do ENEM e do programa é **i.i.d.**¹, a abordagem empírica levaria a resultados *exatamente* iguais ao cálculo via abordagem probabilística!!!

Isso nos diz que:

- Podemos estudar propriedades estatísticas dos fenômenos sociais em que trabalhamos não só restritos a uma determinada amostra em que temos, mas fazendo **generalizações** desses fenômenos;
- Utilizando modelos que representem esses fenômenos, conseguimos ter estimativas do comportamento deles que incorporem **incertezas** inerentes a eles.

Modelagens são formas de adicionar complexidade ao estudo desses fenômenos a partir das suas interações com outros fenômenos sociais.



RELAÇÃO ENTRE MODELOS PROBABILÍSTICOS E MODELOS DE REGRESSÃO

Conhecendo o modelo probabilístico que melhor descreve determinada **variável de interesse**, podemos entender suas propriedades, uma vez que são as mesmas propriedades do modelo probabilístico.

Com isso, podemos:

- **Predição:** Prever resultados futuros condicionados a um conjunto de outras variáveis (probabilidade condicional a um conjunto de X);
- **Associação/Causalidade:** Estabelecer em que medida variando uma outra variável(is), os valores da variável de interesse também variam (probabilidade condicional a um X).
- Obter valores esperados e incerteza de seus resultados (esperança e variância).



RELAÇÃO ENTRE MODELOS PROBABILÍSTICOS E MODELOS DE REGRESSÃO

Conhecendo o modelo probabilístico que melhor descreve determinada **variável de interesse**, podemos entender suas propriedades, uma vez que são as mesmas propriedades do modelo probabilístico.

Com isso, podemos:

- **Predição:** Prever resultados futuros condicionados a um conjunto de outras variáveis (probabilidade condicional a um conjunto de X);
- **Associação/Causalidade:** Estabelecer em que medida variando uma outra variável(is), os valores da variável de interesse também variam (probabilidade condicional a um X).
- Obter valores esperados e incerteza de seus resultados (esperança e variância).

Tudo isso é o que fazemos nos modelos de regressão, graças às propriedades dos modelos probabilísticos subjacentes à variável que estamos interessados.



CONCEITOS E DEFINIÇÕES ESTATÍSTICAS IMPORTANTES

Variável aleatória (v.a.)



VARIÁVEL ALEATÓRIA (V.A.)

Uma variável X é aleatória se cada um de seus valores – ou um intervalo entre valores – está associado a uma probabilidade $p(X)$.



VARIÁVEL ALEATÓRIA

Uma variável X é aleatória se cada um de seus valores – ou um intervalo entre valores – está associado a uma probabilidade $p(X)$.

EXEMPLO

Vamos voltar ao **pé-de-meia**.

Poderíamos dizer que para a variável X definida como ter nota de matemática no ENEM acima da média dos demais participantes do programa, há uma probabilidade $p(X)$, de modo que:

x	$p(X)$
Abaixo ($x = 0$)	0.67
Acima ($x = 1$)	0.33



Variáveis aleatórias *v. a.* apresentam algumas propriedades que serão importantes nos modelos que utilizaremos:

ESPERANÇA DE X

Se uma determinada variável é aleatória e o seu modelo de probabilidade é conhecido, a sua *Esperança* – também chamada de média – pode ser conhecida.

Geralmente é apresentada enquanto: $E(X)$, sendo X uma variável aleatória.

VARIABILIDADE DE X

Se uma determinada variável é aleatória e é conhecido o seu modelo de probabilidade, a sua *variância* – ou sua variabilidade em torno da média – também pode ser conhecida.

Geralmente é apresentada enquanto: $V(X) = E[X - E(X)]^2$, sendo X uma variável aleatória.



RELAÇÃO ENTRE VARIÁVEIS ALEATÓRIAS

Conhecendo-se as propriedades de uma variável aleatória de interesse, pode-se relacionar duas variáveis aleatórias X e Y , de modo que:

$$Y = f(X_1) = X_1$$

Desse modo,

$$E(Y) = E(X_1)$$

Podemos ainda estender essa relação para mais variáveis aleatórias.



RELAÇÃO ENTRE VARIÁVEIS ALEATÓRIAS

Estendendo a mesma relação:

$$Y = f(X_1, X_2, X_3, X_4, \dots, X_n) = X_1 + X_2 + X_3 + X_4 + \dots + X_n$$

Desse modo,

$$E(Y) = E(X_1 + X_2 + X_3 + X_4 + \dots + X_n)$$

$$E(Y) = E(X_1) + E(X_2) + E(X_3) + E(X_4) + \dots + E(X_n)$$

Portanto, tudo o que precisamos saber é qual o modelo probabilístico – $f(\cdot)$ – se associa a determinado fenômeno social Y , que o trataremos como uma *v. a.*


A partir disso, podemos relacionar esse fenômeno social de interesse com outros fenômenos – outras *v. a.*



TIPOS DE VARIÁVEL ALEATÓRIA

As *v. a.* podem ser divididas entre discretas e contínuas

Figure 6A.15: Distributional Choices



CONCEITOS E DEFINIÇÕES ESTATÍSTICAS IMPORTANTES

Algumas nomenclaturas



ALGUMAS NOMENCLATURAS

VARIÁVEL A SER ESTUDADA

Y : Variável dependente - variável a ser medida - variável a ser testada - variável resposta - variável resultado

VARIÁVEIS QUE EXPLICAM A VARIÁVEL DE ESTUDO

X : Variável independente - variável explicativa - variável preditora

VARIÁVEIS INDEPENDENTES QUE NÃO ESTAMOS INTERESSADOS EM ANALISAR

Há muitos casos em que estamos interessados em uma – ou um conjunto de – variável(is) independente(s). Todavia, por razões das propriedades dos modelos e questões teóricas, é importante que insiramos outras variáveis na análise.

Estas são chamadas de **variáveis controle/confundidoras/co-variáveis**¹.



MODELO DE REGRESSÃO LINEAR

Modelo de Regressão Linear Simples (RLS)



MODELO DE REGRESSÃO LINEAR SIMPLES (RLS)


Como a variação de uma determinada variável (independente) afeta a variação de uma outra variável (resposta)?

No caso simplificado do modelo RLS, temos as seguintes características:


- Uma v.a. resposta/dependente de **natureza contínua**: Y
- Uma v.a. explicativa: X
- Um fator de erro do modelo que nos diz quanto da variabilidade de Y que continua não explicado por X : ϵ



RLS: EXEMPLO DE ONTEM



RLS: EXEMPLO DE ONTEM



FORMALIZAÇÃO DE UM MRLS

Dizemos que a representação geral (ou populacional) de um determinado modelo de regressão é dada por:


$$Y_i = \beta_0 + \beta_1 \cdot X_i + \epsilon_i$$

Em que:

- β_0 : intercepto do modelo.
 - Nos diz qual valor Y assume quando X é igualado a 0.
- β_1 : coeficiente do modelo associado à variável X .
 - Nos diz qual a magnitude da mudança em Y quando X varia uma unidade para cima ou para baixo.
 - É também chamado de **inclinação da reta**, devido à suas propriedades estatísticas do modo em que é calculado.
- ϵ_i : como descrito anteriormente, é o quanto não está sendo explicado em Y_i devido à variação estimada em X_i .



RLS: EXEMPLO DE ONTEM



MODELO DE REGRESSÃO LINEAR

Hipóteses dos modelos RLS



HIPÓTESE: INDEPENDÊNCIA ENTRE ERRO E VARIÁVEIS OBSERVADAS

Partindo do nosso modelo RLS para a população,

$$Y_i = \beta_0 + \beta_1 \cdot X_i + \epsilon_i$$

A **hipótese-chave** é que a média dos erros condicionada na variável explicativa X_i é igual a zero, ou seja:

$$E[\epsilon_i | X_i] = 0$$

Em outras palavras, estamos assumindo que não há nenhum fator contido em ϵ que seja correlacionado com X , de modo que β seja um efeito *puro* de X .



Modelo populacional:

$$Y_i = \beta_0 + \beta_1 \cdot X_i + \epsilon_i$$

Quando vamos *estimar* os nossos parâmetros para a nossa amostra, assumimos os valores médios para os nossos i casos observados, isto é:

$$\bar{Y} = \hat{\beta}_0 + \hat{\beta}_1 \cdot \bar{X} + \hat{\epsilon}_i$$

Os únicos valores que não conhecemos são referentes a β_0 e β_1 , uma vez que ϵ é obtido residualmente.

Tudo o que precisamos fazer é **estimar os parâmetros desconhecidos do modelo populacional**.



ESTIMANDO PARÂMETROS DO MODELO

O modelo a ser estimado consiste em:

$$\bar{Y} = \hat{\beta}_0 + \hat{\beta}_1 \cdot \bar{X} + \hat{\epsilon}_i$$

ESTIMADORES DE MÍNIMOS QUADRADOS ORDINÁRIOS (MQO)

Os estimadores de MQO asseguram, via relações estatísticas, que tenhamos valores para nossos parâmetros desconhecidos que **minimizem o desvio dos resíduos**.

Isto é, temos a reta que melhor se ajusta aos nossos dados de modo que passe mais perto possível de cada ponto.



ESTIMANDO PARÂMETROS DO MODELO

Acionando a hipótese descrita anteriormente, temos:

$$\bar{Y} = \hat{\beta}_0 + \hat{\beta}_1 \cdot \bar{X}$$

- $\hat{\beta}_0 = \bar{Y} - [\hat{\beta}_1 \cdot \bar{X}]$
- $\hat{\beta}_1 = \frac{Cov(x,y)}{Var(x)}$
- Valores preditos: $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 \cdot X_i$ para cada observação $i = 1, \dots, n$.
- Resíduos: $\hat{u}_i = y_i - \hat{Y}_i$, para cada observação $i = 1, \dots, n$



Para o exemplo anterior, se partimos do modelo a ser estimado:

$$\overline{Divorcio} = \hat{\beta}_0 + \hat{\beta}_1 \cdot \overline{Margarina} + \hat{\epsilon}$$

Aplicando em R:

```
1 modelo <- lm(divorcio ~ margarina, data = base)
2 modelo
```

Call:

```
lm(formula = divorcio ~ margarina, data = base)
```

Coefficients:

(Intercept)	margarina
3.3086	0.2014



Para o exemplo anterior, se partimos do modelo a ser estimado:

$$\overline{Divorcio} = \hat{\beta}_0 + \hat{\beta}_1 \cdot \overline{Margarina} + \hat{\epsilon}$$

Aplicando em R:

```
1 modelo <- lm(divorcio ~ margarina, data = base)
2 summary(modelo) # indo além nos resultados
```

Call:

```
lm(formula = divorcio ~ margarina, data = base)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.05583	-0.01816	-0.01452	0.03601	0.04625

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3.308626	0.048032	68.88	0.0000000000022 ***
margarina	0.201386	0.008735	23.05	0.0000000132968 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.03841 on 8 degrees of freedom

Multiple R-squared: 0.9852, Adjusted R-squared: 0.9833

F-statistic: 531.5 on 1 and 8 DF, p-value: 0.0000000133



PAUSA!





MODELO DE REGRESSÃO LINEAR

Propriedades do MRL



PROPRIEDADES DO MRL

Para assegurar que, através do MQO, tenhamos estimadores **não viesados** e **mais eficientes**, devemos assegurar que 6 hipóteses sejam asseguradas:

1. O modelo é linear nos parâmetros;
2. Amostra é aleatória e segue o modelo populacional descrito em H1;
3. Inexistência variáveis constantes ou que não tenham uma relação linear exata com outra variável explicativa;
4. Independência entre erro e variáveis observadas;
5. Variância do erro constante para todas as variáveis explicativas;
6. O erro segue uma distribuição normal com média 0 e variância constante



H1: O MODELO É LINEAR NOS PARÂMETROS

Os parâmetros – β s – se relacionam de forma linear.

$$Y_i = \beta_0 + \beta_1 \cdot X_i + \epsilon_i$$

É por essa propriedade que chamamos os modelos de **modelos lineares**.



H2: AMOSTRA É ALEATÓRIA E SEGUE O MODELO POPULACIONAL DESCRITO EM H1

Para uma dada amostra de tamanho N qualquer, seu processo gerador seguiu uma distribuição aleatória, seguindo o modelo populacional descrito em H1.

Todavia, *em casos onde temos problemas de seletividade amostral*, isso pode afetar essa hipótese.

- Exemplo: desigualdades salariais.



H3: INEXISTÊNCIA VARIÁVEIS CONSTANTES OU QUE NÃO TENHAM UMA RELAÇÃO LINEAR EXATA COM OUTRA VARIÁVEL EXPLICATIVA

Para qualquer variável explicativa X , há uma variabilidade de seus resultados em relação a Y .

Além disso, determinada variável X não pode estar totalmente correlacionada com outra variável X .

- Assegura que não haja perfeita colinearidade, i.e., que toda a variação em X_1 esteja associada a X_2 .



H4: INDEPENDÊNCIA ENTRE ERRO E VARIÁVEIS OBSERVADAS

Mencionado anteriormente: a média dos erros condicionada na variável explicativa X_i é igual a zero, ou seja:

$$E[\epsilon_i | X_i] = 0$$

Para um determinado valor de X , os outros fatores não observados no modelo não afetam o resultado de X .

Não é que ϵ não se relacione com Y , e sim que ϵ não está condicionado a X .



H5: VARIÂNCIA DO ERRO CONSTANTE PARA TODAS AS VARIÁVEIS EXPLICATIVAS

$$Var[\epsilon|X] = \sigma^2$$

Chamamos essa hipótese de **homocedasticidade** ou **variância constante do erro**.

Pode ser violada em situações de:

- Outliers para uma variável específica
- Distribuições de alguma variável específica que seguem um distinto padrão.
- ...



H6: O ERRO SEGUE UMA DISTRIBUIÇÃO NORMAL COM MÉDIA 0 E VARIÂNCIA CONSTANTE

Assumindo isso, podemos também assumir, *por propriedades estatísticas*, que qualquer um de nossos parâmetros também têm distribuição normal.

Por que assumimos essa hipótese para o erro e não para os parâmetros?

- O erro pode ser estudado e avaliado, os parâmetros não.



ASSEGURANDO A EXISTÊNCIA DE H1-H4

Estimadores MQO **não viesados**. Isto é, representam o que seria o valor a ser obtido na população estudada, mesmo depois de implementar em N diferentes amostras.

- $E[\hat{\beta}_0 | X] = \beta_0$
- $E[\hat{\beta}_1 | X] = \beta_1$



ASSEGURANDO A EXISTÊNCIA DE H1-H4

Estimadores MQO **não viesados**. Isto é, representam o que seria o valor a ser obtido na população estudada, mesmo depois de implementar em N diferentes amostras.

- $E[\hat{\beta}_0 | X] = \beta_0$
- $E[\hat{\beta}_1 | X] = \beta_1$

ASSEGURANDO A EXISTÊNCIA DE H5

Estimadores MQO sendo **os mais eficientes**. Isto é, asseguram a menor variância possível dentre outros processos de estimação dos parâmetros.



ASSEGURANDO A EXISTÊNCIA DE H1-H4

Estimadores MQO **não viesados**. Isto é, representam o que seria o valor a ser obtido na população estudada, mesmo depois de implementar em N diferentes amostras.

- $E[\hat{\beta}_0 | X] = \beta_0$
- $E[\hat{\beta}_1 | X] = \beta_1$

ASSEGURANDO A EXISTÊNCIA DE H5

Estimadores MQO sendo **os mais eficientes**. Isto é, asseguram a menor variância possível dentre outros processos de estimação dos parâmetros.

ASSEGURANDO A EXISTÊNCIA DE H1-H5

Temos os melhores estimadores para o modelo populacional. À medida que aumenta o tamanho da amostra, aproxima-se mais do valor do parâmetro na população e com menor incerteza sobre ele.



ASSEGURANDO A EXISTÊNCIA DE H1-H4

Estimadores MQO **não viesados**. Isto é, representam o que seria o valor a ser obtido na população estudada, mesmo depois de implementar em N diferentes amostras.

- $E[\hat{\beta}_0 | X] = \beta_0$
- $E[\hat{\beta}_1 | X] = \beta_1$

ASSEGURANDO A EXISTÊNCIA DE H5

Estimadores MQO sendo **os mais eficientes**. Isto é, asseguram a menor variância possível dentre outros processos de estimação dos parâmetros.

ASSEGURANDO A EXISTÊNCIA DE H1-H5

Temos os melhores estimadores para o modelo populacional. À medida que aumenta o tamanho da amostra, aproxima-se mais do valor do parâmetro na população e com menor incerteza sobre ele.

ASSEGURANDO A EXISTÊNCIA DE H1-H6

É possível fazer inferência sob a significância estatística dos coeficientes estimados em comparação com o valor do parâmetro na população.



EXEMPLO DA AULA!

...



ACESSO AO ESGOTAMENTO SANITÁRIO

Pergunta: Quais os fatores associados ao acesso ao esgotamento sanitário de populações vulneráveis no Brasil?

Mais especificamente, qual a associação entre acesso ao Programa Bolsa Família para famílias com jovens entre 15-29 anos e o acesso ao esgotamento sanitário?

DADOS


Uma base de dados construída com dados do CadÚnico e Censo Demográfico 2010.



VAMOS LÁ!

...





MODELO DE REGRESSÃO LINEAR

Modelo de Regressão Linear Múltipla (RLM)



MODELO DE REGRESSÃO LINEAR MÚLTIPLA (RLM)

No caso dos modelos RLS, havia somente uma variável explicativa.

Todavia, pode ser que haja outros fenômenos sociais que estejam:

1. Associados com a nossa variável de interesse Y
2. Associados com a nossa variável explicativa X



NO CENÁRIO 1

Se temos na base de dados a variável explicativa que sabemos que está associada com Y , por que não a incluir?

GANHOS DE INCLUIR

- Reduz a variância não explicada do modelo – contida em ϵ
- Aumenta a capacidade de predição do modelo

PERDAS DE INCLUIR

- Parcimônia do modelo: *the simpler, the better!*



NO CENÁRIO 2

Se sabemos que está associada com X , ela deve ser incluída.

GANHOS DE INCLUIR

- Não violação de H4 – independência entre o erro e as variáveis observadas.
- Reduz a variância não explicada do modelo – contida em ϵ

PERDAS DE INCLUIR

- Neste caso, não há.



FORMALIZAÇÃO

$$Y_i = \beta_0 + \beta_1 \cdot X_{1i} + \beta_2 \cdot X_{2i} + \dots + \beta_k \cdot X_{ki} + \epsilon_i$$

Em que:

- k é o número de parâmetros associados às variáveis explicativas/independentes incluídas no modelo.



O QUE MUDA ENTRE RLS E RLM?

Em RLS, temos o modelo populacional descrito como:

$$Y_i = \beta_0 + \beta_1 \cdot X_{1i} + \epsilon_i$$

Enquanto em RLM, temos:

$$Y_i = \beta_0 + \beta_1 \cdot X_{1i} + \beta_2 \cdot X_{2i} + \dots + \beta_k \cdot X_{ki} + \epsilon_i$$



O QUE MUDA ENTRE RLS E RLM?

Em RLS, temos o modelo populacional descrito como:

$$Y_i = \beta_0 + \beta_1 \cdot X_{1i} + \epsilon_i$$

Enquanto em RLM, temos:

$$Y_i = \beta_0 + \beta_1 \cdot X_{1i} + \beta_2 \cdot X_{2i} + \dots + \beta_k \cdot X_{ki} + \epsilon_i$$

Adicionar mais variáveis ao modelo nos dá maior confiança de que estaremos cumprindo os pressupostos para se ter estimadores **não viesados e mais eficientes**.



O QUE MUDA ENTRE RLS E RLM?

Em RLS, temos o modelo populacional descrito como:

$$Y_i = \beta_0 + \beta_1 \cdot X_{1i} + \epsilon_i$$

Enquanto em RLM, temos:

$$Y_i = \beta_0 + \beta_1 \cdot X_{1i} + \beta_2 \cdot X_{2i} + \dots + \beta_k \cdot X_{ki} + \epsilon_i$$

Adicionar mais variáveis ao modelo nos dá maior confiança de que estaremos cumprindo os pressupostos para se ter estimadores **não viesados e mais eficientes**. Aumenta a complexidade dos modelos também...



O QUE MUDA ENTRE RLS E RLM?

INTERPRETAÇÃO DOS MODELOS RLM

Nos modelos RLM, temos que invocar a noção de *ceteris paribus* para uma correta interpretação dos resultados.

CETERIS PARIBUS: “tudo o mais é constante”.

- Mantendo-se todos os outros fatores fixos, constantes, pode-se interpretar como a variação em determinada variável explicativa X_k se relaciona com Y .



EXEMPLO DA AULA!

Parte 2



VAMOS FAZER O NOSSO MODELO UM POUCO MAIS COMPLEXO

Vamos estimar 3 diferentes modelos:

MODELO 1

O mesmo estimado no exercício anterior - já temos código e tudo mais!

MODELO 2

Adicione ao **Modelo 1**, a variável informalidade (*informalidade*)

MODELO 3

Adicione ao **Modelo 1**, variável frequência ao ensino médio (*em*)

MODELO 4

Adicione ao **Modelo 1**, as variáveis que adicionamos no **Modelo 2 e 3**




VAMOS LÁ!

Dica (código em R para modelo com 2 variáveis explicativas):

```
modelo2 = lm(Var_Y ~ Var_X1 + Var_X2, data = dados)
```





ISSO É TUDO PARA HOJE!

Para próxima aula:

1. Exercício sobre Regressão Linear Múltipla (próximo slide)
2. Leitura de material para aula de hoje (caso não tenha lido)
3. Leitura de material para a aula seguinte (Ver ementa)



ORIENTAÇÕES SOBRE O EXERCÍCIO

Utilizaremos os mesmos dados que utilizamos na aula de hoje.

- Rode o Modelo 1 da aula de hoje e interprete os resultados
- Adicione ao modelo 1, a variável do Modelo 2 da aula de hoje e interprete os resultados de cada variável;
- Adicione ao Modelo 2, a variável do Modelo 3 da aula de hoje e interprete os resultados de cada variável;
- Adicione a variável `municipio_rural` e interprete os resultados dela;
- Volte às estatísticas do modelo – obtidas com `summary()` – e compare se houve muita mudança nos coeficientes de cada uma das variáveis quando incluída outras variáveis ao modelo. **O que isso nos diz?**
- Observe se o R^2 – obtidos com `summary()` – apresentou muita mudança entre os modelos. **O que isso nos diz?**





CEBRAP

Presidência Adrian Gurza Lavalle

Diretoria Administrativa Victor Callil

Diretoria Científica Arilson Favareto

Coordenação de Seminários Bianca Tavorari

Coordenação de Cursos Monise Fernandes Picanço

Curso

Introdução à análise de regressão para pesquisas sociais

Ministrante

Thiago Cordeiro Almeida

E-mail: thiagocordalmeida@gmail.com

Github: [@thiagocalm](https://github.com/thiagocalm)

